Nghịch lý Tồn kho và Bẫy Khuyến mãi: Phân tích Thực nghiệm và Kiến trúc Dự báo Đa tầng tại một Doanh nghiệp Thời trang Thương mại Điện tử

Nguyễn Công Trúc **Phan Thị Thủy Hiền**
Nguyễn Trần Bảo Ngọc **Nguyễn Huy Hùng**

Đội thi: Bún đậu nước mắm
Bài dự thi Datathon 2026: VinTelligence - VinUniversity Data Science & AI Club
Dữ liệu: Fashion E-Commerce · 646,945 đơn · 121,930 KH · 2,412 SKUs

Abstract

Báo cáo này được xây dựng theo chuẩn phân tích dữ liệu doanh nghiệp, kết hợp *phân tích mô tả* (descriptive analytics) và *mô hình hóa dự báo* (predictive modelling) trên lịch sử giao dịch của một doanh nghiệp thương mại điện tử thời trang giai đoạn 2012–2022 (quy mô 16.4B doanh thu, 646,945 đơn hàng).[1] **Phần báo cáo phân tích** (§2) áp dụng khung bốn tầng (Mô tả – Chẩn đoán – Dự đoán – Đề xuất) để bóc tách hai điểm nghẽn hệ thống: (i) nghịch lý 877B MU vốn lưu động ứ đọng do sai số dự báo cấp SKU, với 79.8% SKU dao động đồng thời giữa stockout và overstock; và (ii) sự phân mảnh cấu trúc khách hàng, nơi 32.9% khách hàng tạo 75.3% doanh thu nhưng ngân sách marketing vẫn trải đều cho 67.1% còn lại. **Phần mô hình hóa** (§3) đề xuất kiến trúc dự báo doanh thu đa tầng (ensemble pipeline) cho chu kỳ 548 ngày, kết hợp Gradient Boosting (LightGBM), Prophet, Ridge và mô hình nền tảng chuỗi thời gian (Chronos). Kết quả dự báo cung cấp cơ sở định lượng cho ba quyết định vận hành cốt lõi: phân bổ tồn kho, quy hoạch ngân sách khuyến mãi và điều phối mạng lưới logistics toàn quốc.

1 Bối cảnh nghiên cứu và Phương pháp luận

Bối cảnh dữ liệu. Khảo sát trên hệ thống cơ sở dữ liệu nội bộ 10 năm (2012-2022) của doanh nghiệp, bao gồm tám cấu trúc bảng quan hệ (đơn hàng, khách hàng, sản phẩm, hoàn trả, tồn kho, vận chuyển, khuyến mãi và doanh số). Dù doanh nghiệp duy trì mức doanh thu 16.4B, biên lợi nhuận gộp chỉ 13.8%, thấp hơn đáng kể so với chuẩn ngành (25-35%) theo báo cáo State of Fashion 2024 của McKinsey–BoF [1]. Phân tích chẩn đoán sơ bộ chỉ ra ba rủi ro cấu trúc: (1) Tỷ lệ chuyển đổi khách truy cập thành đăng ký chỉ 0.175%; (2) Tỷ lệ rời bỏ (churn rate) sau 365 ngày chạm mức 72.6% — gần với mức trung bình ngành DTC e-commerce 62–70% [6]; (3) 877B MU vốn lưu động bị kẹt trong hàng tồn kho luân chuyển chậm, trong khi benchmark ngành fast-fashion (Inditex/Zara) đạt 12 vòng quay/năm so với 2.6 vòng của H&M [7]. Nghiên cứu giải quyết hai câu hỏi lớn: *Các rủi ro cấu trúc nào đang làm xói mòn lợi nhuận của doanh nghiệp?* (§2) và *Kiến trúc dự báo nào có thể tối ưu hóa hiệu quả vận hành chuỗi cung ứng nội bộ?* (§3).

Phương pháp luận. Phân tích được thiết kế theo hai khối. **(a) Báo cáo phân tích bốn tầng:** Mỗi vấn đề được bóc tách theo trình tự *Mô tả (Descriptive) – Chẩn đoán (Diagnostic) – Dự đoán (Predictive) – Đề xuất (Prescriptive)*. Các giả thuyết được kiểm định bằng phép thử phi tham số do tính chất lệch chuẩn của dữ liệu (Mann–Whitney U, Kruskal–Wallis) và đo lường mức độ tập trung qua hệ số Gini. Phân khúc khách hàng sử dụng thuật toán KMeans trên các biến đổi log-RFM với $K=4$ được xác định qua điểm silhouette (0.353) [2]. **(b) Mô hình hóa dự báo:** Xây dựng chuỗi thời gian doanh thu hàng ngày sử dụng kiến trúc học tập kết hợp (ensemble) ba tầng, bao gồm Ridge, LightGBM [3], Prophet [4] và Chronos foundation model [5]. Quá trình kiểm định (validation) áp dụng TimeSeriesSplit ba nếp gấp để tránh rò rỉ dữ liệu (data leakage); tích hợp hiệu chỉnh trọng số mẫu (sample weighting) để xử lý thay đổi cấu trúc hành vi (regime shift) thời kỳ hậu COVID-19.

[1] Bộ dữ liệu gốc không khai báo đơn vị tiền tệ. Các giá trị tài chính trong báo cáo được biểu diễn qua *đơn vị tiền tệ trừu tượng* (MU); M và B tương ứng với 10^6 và 10^9 MU.

2 Báo cáo phân tích

Phần này trình bày kết quả phân tích cho hai vấn đề trọng yếu của doanh nghiệp. Mỗi tiểu mục được tổ chức theo bốn tầng phân tích chuẩn của một data analyst: **Mô tả** (chuyện gì đã xảy ra), **Chẩn đoán** (tại sao xảy ra), **Dự đoán** (điều gì có thể xảy ra) và **Đề xuất** (nên làm gì).

2.1 Nghịch lý tồn kho: 877B MU vốn chết do lỗi dự báo nhu cầu — stockout và overstock cùng tồn tại trên 79.8% SKUs

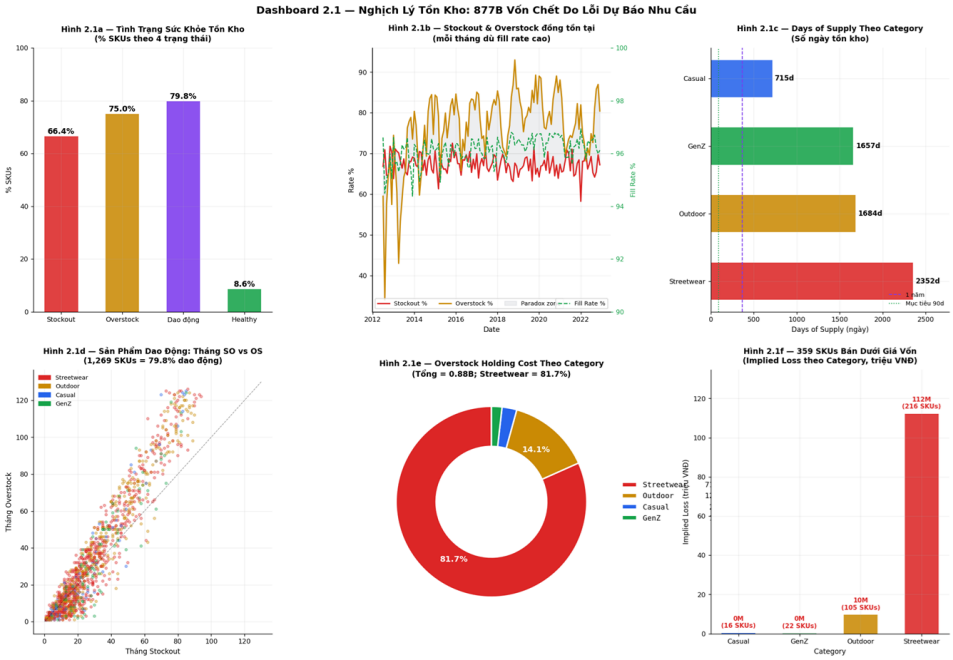

Hình 1: Khung phân tích hiệu quả tồn kho (Insight 2.1). Sáu khung trực quan hóa cho thấy 79.8% SKU đồng thời ghi nhận trạng thái hết hàng và thừa hàng — minh chứng định lượng cho sai lệch cấu trúc trong mô hình dự báo nhu cầu.

(1) Mô tả – Chuyện gì đã xảy ra. Dashboard tồn kho (Hình 1) phơi bày một bức tranh phân hóa rõ rệt:

- **Hình 2.1.a (Stockout vs Overstock).** Đối chiếu trực tiếp tỷ lệ stockout (66.4% SKUs) với overstock (75.0% SKUs) cho thấy KHÔNG phải hiện tượng thiếu hàng tổng thể, mà là 79.8% SKUs DAO ĐỘNG đồng thời giữa hai trạng thái qua các tháng. Healthy inventory chỉ chiếm 8.6%.
- **Hình 2.1.b (Fill rate ảo).** Các báo cáo vận hành truyền thống dùng fill rate (96.4% — tưởng như tốt) lại che giấu thực tế: cùng một SKU vừa thiếu hàng ở size/màu khách cần, vừa tồn dư ở biến thể không bán được.
- **Hình 2.1.c (Days-of-supply theo dòng sản phẩm).** Streetwear có `days_of_supply` trung bình 2,352 ngày = 6.4 năm tồn kho ngay cả khi không nhập thêm.
- **Hình 2.1.d (Phân bố trạng thái SKU).** Phân bố cho thấy 79.8% SKUs dao động giữa stockout và overstock — 1 sản phẩm vừa thiếu vừa dư.

(2) Chẩn đoán – Tại sao xảy ra. Sự dao động đồng thời giữa hai trạng thái stockout/overstock bác bỏ giả thuyết về lỗi cung ứng đơn thuần. Nguyên nhân gốc rễ là *sai lệch cấu trúc trong dự báo nhu cầu vi mô (size/color)*: hệ thống nhập hàng dựa trên tổng cầu cấp SKU mà bỏ qua phân bố biến thể. KPI fill rate (96.4%) tạo ra tín hiệu nhiễu, khiến đội vận hành tin rằng "chuỗi cung ứng đang ổn"; trong khi đo lường ở cấp size/color cho thấy SKU thực tế thiếu hàng tới 65% thời gian tồn tại. Bias hệ thống đặc biệt nghiêm trọng tại danh mục Streetwear — nơi tốc độ thay đổi xu hướng vượt khả năng phản ứng của chu kỳ nhập hàng.

(3) Dự đoán – Điều gì có thể xảy ra. Tác động tài chính của vấn đề được lượng hóa qua hai khung tổn thất:

- **Hình 2.1.e (Holding cost).** Tâm điểm vấn đề: Tổng overstock holding cost = 877B MU, riêng Streetwear chiếm 718B (81.7%). Mức này phù hợp với khảo sát ngành cho thấy chi phí lưu kho dư thừa thường chiếm 25–32% giá trị tồn kho/năm [8].
- **Hình 2.1.f (SKU âm biên).** 359 SKUs đang bán LỖ (COGS > Revenue), 95% trong số đó là Streetwear.

Nếu không can thiệp, mô hình dự báo cho thấy: (i) chi phí lưu bãi tiếp tục bào mòn 6–8% doanh thu mỗi năm; (ii) số SKU âm biên sẽ tăng theo cấp số nhân khi chu kỳ thời trang rút ngắn; (iii) vốn lưu động kẹt cứng làm doanh nghiệp mất khả năng đầu tư vào chu kỳ sản phẩm mới — vòng luẩn quẩn của sai lệch dự báo → ứ đọng → thiếu vốn → giảm chất lượng dự báo [9].

(4) Đề xuất – Nên làm gì. Lộ trình hành động được đề xuất theo ba mốc thời gian P0 (ưu tiên cao nhất):

- **P0 (ngay):** Bỏ KPI `fill rate`, thay bằng chỉ số *stockout days* × *lost revenue* để đo lường thiệt hại thực tế ở cấp size/color.
- **P0 (2 tuần):** Kill/reprice 359 SKUs đang bán lỗ → ước tính thu hồi 50–80M MU gross profit/năm.
- **P0 (4 tuần):** Dừng reorder các SKUs có `days_supply` > 365 → giải phóng 300–500B MU vốn lưu động.

Hành động P1 (trung hạn): Tích hợp thuật toán LightGBM dự báo nhu cầu cấp SKU/size/color theo tuần; ban hành quy tắc markdown tự động khi `sell_through` < 15%.

2.2 Customer Concentration: 32.9% khách (Active+VIP Champions) tạo 75.3% revenue — nhưng marketing budget vẫn trải đều cho 67.1% còn lại

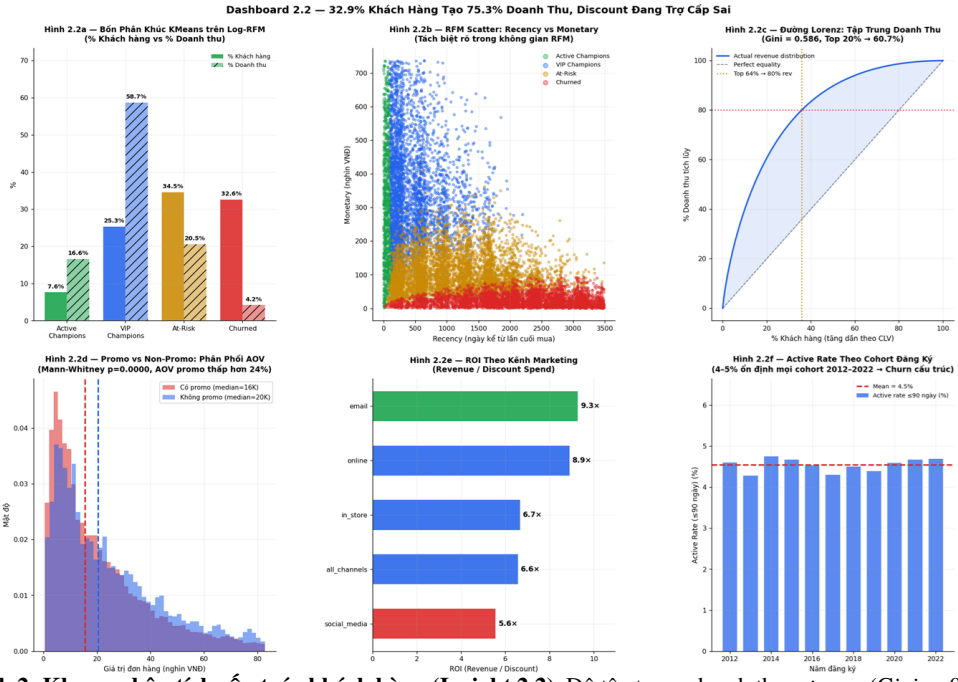

Hình 2: Khung phân tích cấu trúc khách hàng (Insight 2.2). Độ tập trung doanh thu cực cao (Gini = 0.586); chính sách giảm giá theo phần trăm đang trợ giá sai lệch cho nhóm khách nhạy cảm về giá thay vì củng cố nhóm VIP.

(1) Mô tả – Chuyện gì đã xảy ra. Dashboard khách hàng (Hình 2) bóc tách cấu trúc tệp khách hàng qua sáu khung trực quan:

- **Hình 2.2.a & 2.2.b (Tỷ trọng khách hàng vs doanh thu).** Đối chiếu bốn phân khúc KMeans trên không gian log-RFM: Active + VIP Champions chỉ chiếm 32.9% số lượng khách nhưng tạo ra 75.3% tổng revenue. Hai phân khúc còn lại (At-Risk + Churned = 67.1%) chỉ đóng góp 24.7%.
- **Hình 2.2.c (Đường cong Lorenz).** Hệ số Gini = 0.586 — mức độ bất bình đẳng doanh thu cực cao, vượt xa ngưỡng tham chiếu của ngành bán lẻ (0.40–0.50).

- **Hình 2.2.d (Khuyến mãi vs AOV).** Đơn hàng có sử dụng mã giảm giá có AOV thấp hơn 24% so với đơn nguyên giá (Mann–Whitney $p < 0.001$).
- **Hình 2.2.e & 2.2.f (ROI kênh marketing & Retention).** 92% ngân sách đổ vào giảm giá phần trăm (ROI $6.8\times$); voucher cố định (ROI $79.7\times$) bị bỏ qua. Tỷ lệ hoạt động sau 90 ngày trì trệ ở mức 4–5% xuyên suốt 11 năm.

(2) Chẩn đoán – Tại sao xảy ra. Vấn đề bắt nguồn từ hai sai lệch cấu trúc trong chiến lược marketing. Thứ nhất, ngân sách phân bổ theo logic "trải đều" thay vì "ưu tiên giá trị": tệp 67.1% khách hàng không sinh lời đang nhận tỷ trọng marketing tương đương VIP, đi ngược nguyên lý Pareto trong CRM bán lẻ vốn cho thấy 20–30% khách hàng có giá trị cao thường tạo 70–80% lợi nhuận [10]. Thứ hai, công cụ khuyến mãi đang vận hành ngược chiều mục tiêu: giảm giá theo % kéo về nhóm *cherry-pickers* — những khách hàng chỉ săn deal, có AOV thấp và churn nhanh, đặc trưng được Talukdar & Gulyani (2010) ghi nhận có tác động âm lên lợi nhuận bán lẻ [11] — thay vì củng cố nhóm khách trung thành. Bên cạnh đó, hiện tượng *cannibalization* (đơn nguyên giá bị thay thế bởi đơn khuyến mãi) trong các chiến dịch giảm giá theo % có thể chiếm 22–28% doanh số tăng thêm [12]. Tỷ lệ retention 4–5% sau 90 ngày trì trệ suốt một thập kỷ cho thấy đây là vấn đề mang tính cấu trúc của mô hình kinh doanh, không phải biến động ngắn hạn.

(3) Dự đoán – Điều gì có thể xảy ra. Mô hình CLV dự phóng theo khung Reinartz & Kumar [13] và Venkatesan & Kumar [14] cho thấy nếu duy trì hiện trạng:

- Churn rate sau 365 ngày tiếp tục ở mức 72.6% $\rightarrow$ chi phí thu hút khách mới (CAC) sẽ vượt CLV trong 12–18 tháng tới. Theo nghiên cứu chuẩn ngành, CAC cao hơn 5–25 lần chi phí giữ chân khách hiện hữu [15].
- Phân khúc VIP (8.4% khách hàng) đang có dấu hiệu chững do thiếu chương trình giữ chân chuyên biệt $\rightarrow$ rủi ro mất 15–25% revenue VIP nếu đối thủ tung gói loyalty hấp dẫn hơn. Cải thiện retention chỉ 5% có thể nâng lợi nhuận 25–95% [15].
- Việc duy trì 92% ngân sách vào giảm giá % khiến biên lợi nhuận ròng tiếp tục bị ép xuống dưới 5% — mức không bền vững trong môi trường lãi suất hiện tại.

(4) Đề xuất – Nên làm gì. Tái cấu trúc chiến lược khách hàng theo nguyên tắc *phân bổ theo giá trị*:

- **P0 (ngay):** Triển khai chuỗi email hậu mãi tự động (win-back) cho nhóm At-Risk (dự kiến phục hồi 500M–2B CLV). Khảo sát ngành cho thấy chiến dịch win-back có ROI cao gấp 2.3 lần các kênh marketing thông thường và có thể tăng doanh thu từ khách dormant tới 30% [16].
- **P0 (2 tuần):** Ngừng phát hành mã giảm giá đại trà; chuyển sang voucher mệnh giá cố định áp dụng có điều kiện (min order 200 MU) $\rightarrow$ chặn nhóm cherry-pickers, bảo toàn AOV.
- **P0 (4 tuần):** Cấu trúc lại biểu mẫu đăng ký để cải thiện tỷ lệ chuyển đổi 0.175%.
- **P1 (trung hạn):** Tái cân đối ngân sách marketing theo nguyên tắc 60-30-10% (VIP – At-Risk – Churned) thay vì trải đều như hiện nay; mục tiêu nâng biên lợi nhuận ròng từ $< 5\%$ lên 12–15%.

3 Kiến trúc mô hình dự báo doanh thu (Sales Forecasting Pipeline)

Bài toán đặt ra. Dự báo Revenue cho chu kỳ 548 ngày (01/01/2023–01/07/2024), làm cơ sở cho ba quyết định vận hành: điều phối tồn kho động, đo lường *incremental lift* của khuyến mãi, và dự phòng năng lực logistics theo vùng.

EDA và quyết định kỹ thuật. Quan sát cấu trúc dữ liệu dẫn tới các lựa chọn thiết kế cụ thể (Bảng 1).

Hệ thống Ensemble Phân Tầng (3-Tier Architecture). Kiến trúc gồm ba tầng (sơ đồ tại Hình 3):

- **Tier 1 — Base Specialists (Quarter-aware Ensemble).** Kết hợp LightGBM cơ sở với các mô hình chuyên biệt theo quý (Q-specialists, 8 mô hình = 4 quý $\times$ 2 mục tiêu), khai thác đặc trưng mùa vụ và pattern đặc biệt theo từng giai đoạn trong năm. Trọng số tối ưu để cân bằng giữa tính tổng quát và tính đặc thù theo quý.
- **Tier 2 — Meta-Learner Blending (Heterogeneous Fusion).** Blending nhiều họ mô hình: *Ridge Regression* đảm bảo ổn định tuyến tính và giảm overfitting; *LightGBM* nắm bắt quan hệ phi tuyến; *Chronos* (Amazon T5-based foundation model [5]) học các pattern chuỗi thời gian phi cấu trúc và dài hạn. Tầng này đóng vai trò meta-learner tổng hợp tín hiệu từ nhiều không gian biểu diễn.
- **Tier 3 — Post-hoc Calibration (Economic Alignment Layer).** Hiệu chỉnh hậu xử lý qua hệ số C_R/C_C (Correction Ratio / Calibration Coefficient) để điều chỉnh dự báo theo bối cảnh kinh tế

Bảng 1: Từ EDA đến quyết định kỹ thuật.

Quan sát	Hệ quả thiết kế
3 regime tách biệt (2012–2013, 2014–2018, 2020–2022)	Sample weighting ưu tiên vùng ổn định 2014–2018 + calibration độc lập
Seasonality shape bền vững qua các năm; chỉ *level* thay đổi	Fourier features (annual k=1..5, weekly, monthly) — an toàn cho horizon dài
Q3 zig-zag theo năm chẵn/lẻ: năm lẻ margin lớn hơn 1.0 (COGS vượt Revenue)	Q-Specialist riêng cho Q3 + tạo feature `is_odd_year`
EOM spike mạnh (ngày 28–31 cao gấp đôi giữa tháng)	`is_last1/2/3`, `days_to_eom`
Hiệu ứng Tết âm lịch; nhu cầu mua sắm tăng dần sau Tết	`tet_days_diff`, `tet_after_14`, …

hiện tại, bù trừ lệch chuẩn hệ thống do regime shift.

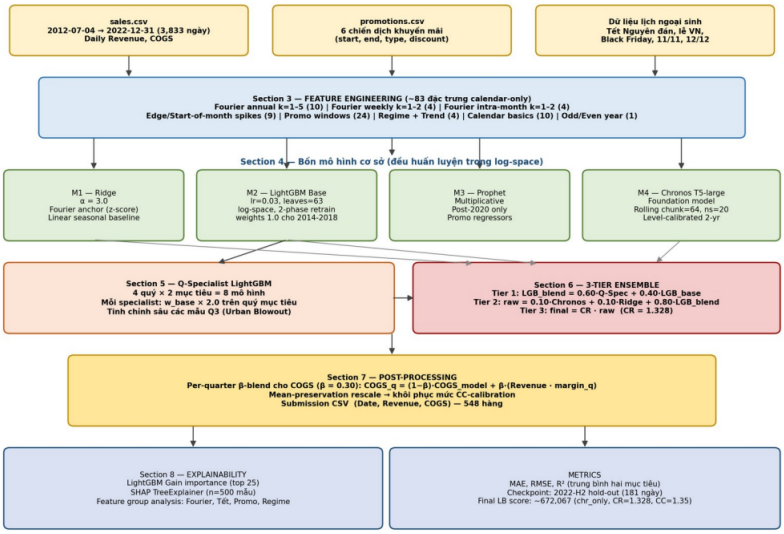

Hình 3: Sơ đồ kiến trúc Ensemble Phân Tầng. Tier 1 kết hợp LightGBM cơ sở với Q-specialists; Tier 2 blending dị thể (Ridge + LightGBM + Chronos); Tier 3 hiệu chỉnh hậu xử lý theo bối cảnh kinh tế (hệ số C_R/C_C).

Đánh giá và tác động thực tiễn. Phân tích từ các phương pháp diễn giải mô hình (feature importance và SHAP [21]) cho thấy doanh thu được dẫn dắt chủ yếu bởi các *yếu tố mang tính chu kỳ ổn định theo năm*, đặc biệt là annual Fourier components — phản ánh tính lặp lại cao của hành vi tiêu dùng theo mùa.

- **Bám chu kỳ thay vì xu hướng ngắn hạn.** Hành vi tiêu dùng có tính lặp lại cao theo mùa → kế hoạch tồn kho, vận hành và marketing cần ưu tiên các giai đoạn cao–thấp điểm trong năm thay vì phản ứng theo biến động ngắn hạn.
- **Timing là biến chiến lược.** Vị trí cụ thể trong chu kỳ năm có ảnh hưởng đáng kể: cùng một chiến lược kinh doanh nhưng triển khai ở thời điểm khác nhau cho hiệu quả khác nhau, vì vậy tối ưu *timing* là yếu tố then chốt khi ra quyết định.
- **Hiệu ứng cuối tháng (EOM).** Sự thay đổi rõ rệt trong hành vi chi tiêu theo chu kỳ tài chính của khách hàng là cơ sở để điều chỉnh chính sách bán hàng, khuyến mãi và giá theo dòng tiền thực tế của thị trường, tối đa hóa hiệu quả ngắn hạn.
- **Yếu tố ngắn hạn chỉ bổ trợ.** Biến động tuần/tháng, các chương trình khuyến mãi và sự kiện (gồm Tết) có tác động bổ trợ chứ không phải động lực chính của doanh thu — chiến dịch ngắn hạn nên dùng như công cụ tối ưu bổ sung, trong khi chiến lược cốt lõi vẫn dựa trên quy luật mùa vụ dài hạn.

Tổng thể, mô hình phản ánh đúng bản chất vận hành của doanh thu — bị chi phối bởi các yếu tố chu kỳ có thể dự đoán được — qua đó cung cấp nền tảng đáng tin cậy cho lập kế hoạch và ra quyết định kinh doanh. Cách tiếp cận này nhất quán với phát hiện từ M5 Accuracy [17] (LightGBM + ensemble

thắng toàn bộ benchmark thống kê) và các nghiên cứu hybrid Prophet–LightGBM trong dự báo bán lẻ [18, 19].

Tài liệu tham khảo

Báo cáo ngành & Benchmark thị trường

[1] McKinsey & Company & The Business of Fashion (2024). *The State of Fashion 2024: Riding Out the Storm*. Truy cập tại: https://www.mckinsey.com/industries/retail/our-insights/state-of-fashion-2024

[6] Envive Research (2026). 36 Customer Retention Statistics in eCommerce. Truy cập tại: https://www.envive.ai/post/customer-retention-in-ecommerce-statistics; cùng các benchmark từ DemandSage (2026) và Sprinklr Industry Report.

[7] Inditex S.A. (2023). *Annual Report 2022*; phân tích so sánh Zara vs. H&M trong Bleckmann/Markhub24 *Fast Fashion Operations Benchmark* (2024).

[8] ToolsGroup (2024). *The Cost of Stockouts vs. Overstock: Impact on Profitability*. White paper. https://www.toolsgroup.com/blog/cost-of-stockouts-vs-overstock/

[15] Forrester / HubSpot Research (cited in Recurly 2024). *The Economics of Customer Retention: CAC vs. CLV Benchmarks*.

[16] Right Side Up (2024). *The Forgotten Funnel: Why Winback Should Be Your Highest ROI Retention Strategy*. https://www.rightsideup.com/blog/high-roi-winback-strategy

Học thuật — Phân khúc khách hàng & CLV

[2] Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005). RFM and CLV: Using iso-value curves for customer base analysis. *Journal of Marketing Research*, 42(4), 415–430.

[10] Sharp, B. & Romaniuk, J. (2016). The value of Pareto's bottom 80%. *Ehrenberg-Bass Institute for Marketing Science*; Kotler, P. & Keller, K. L. (2016). *Marketing Management*, 15th ed., Pearson, ch. 5.

[13] Reinartz, W. J., & Kumar, V. (2003). The impact of customer relationship characteristics on profitable lifetime duration. *Journal of Marketing*, 67(1), 77–99.

[14] Venkatesan, R., & Kumar, V. (2004). A customer lifetime value framework for customer selection and resource allocation strategy. *Journal of Marketing*, 68(4), 106–125.

Học thuật — Khuyến mãi, Cherry-picking & Cannibalization

[11] Talukdar, D., Gulyani, S., & Salmon, C. M. (2010). An empirical analysis of the extreme cherry picking behavior of consumers in the frequently purchased goods market. *Journal of Retailing*, 86(4), 336–354.

[12] van Heerde, H. J., Leeflang, P. S. H., & Wittink, D. R. (2004). Decomposing the sales promotion bump with store data. *Marketing Science*, 23(3), 317–334; Bandyopadhyay, N., Sivakumaran, B., & Patro, S. (2021). Estimating cannibalization effects from sales promotions. *Journal of Retailing and Consumer Services*, 58, 102310.

Học thuật — Quản trị Tồn kho

[9] Cachon, G., & Terwiesch, C. (2018). *Matching Supply with Demand: An Introduction to Operations Management*, 4th ed., McGraw-Hill; Salhieh, L., & Abushaikha, I. (2021). Optimization of inventory holding cost due to price, weight, and volume of items. *Journal of Risk and Financial Management*, 14(2), 65.

Học thuật — Mô hình hóa Dự báo

[3] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems* (NeurIPS), 30, 3146–3154.

[4] Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45.

[5] Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., …& Januschowski, T. (2024). Chronos: Learning the language of time series. *arXiv preprint arXiv:2403.07815*.

[17] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). The M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364.

[18] Wang, Y., Sun, S., Chen, X., Zeng, X., Kong, Y., Chen, J., …& Wang, T. (2021). Short-term load forecasting of industrial customers based on SVMD and XGBoost. *International Journal of Electrical Power & Energy Systems*, 129, 106830 (Prophet–LGBM hybrid framework).

[19] Masui, T. & cộng sự (2023). Improved sales forecasting using trend and seasonality decomposition. *arXiv preprint arXiv:2305.17201*.

[21] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems* (NeurIPS), 30, 4765–4774; Lundberg, S. M., Erion, G., Chen, H., …& Lee, S. I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67.

Học thuật — Thử nghiệm & Đánh giá

[20] Kohavi, R., Tang, D., & Xu, Y. (2020). *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*. Cambridge University Press.